

# INTRODUCCIÓN A LA ESTADÍSTICA DESCRIPTIVA

## 1. Qué es la estadística

La estadística es una disciplina que permite organizar, resumir, analizar e interpretar datos. Dentro de ella suelen distinguirse dos grandes ámbitos: la **estadística descriptiva** y la **estadística inferencial**. La primera se ocupa de describir y resumir las características esenciales de un conjunto de datos; la segunda permite realizar inferencias o conclusiones sobre una población a partir de una muestra. Esta distinción es fundamental, porque en la práctica investigadora ambas ramas están relacionadas, pero cumplen funciones diferentes.

### 1.2. Qué es la estadística descriptiva

La estadística descriptiva es la rama de la estadística que se centra en describir y resumir las características esenciales de un conjunto de datos. Su objetivo principal es proporcionar una comprensión clara y concisa de la información mediante el uso de medidas descriptivas, como promedios, medianas, desviaciones estándar y otras medidas relacionadas con la distribución de los datos. En otras palabras, la estadística descriptiva no pretende demostrar relaciones causales ni generalizar por sí sola a toda una población, sino ofrecer una imagen organizada y comprensible de la muestra o del conjunto de observaciones disponibles.

### 1.3. Por qué es importante en ciencias de la salud

En ciencias de la salud, la estadística descriptiva es especialmente importante porque permite organizar y presentar de forma significativa una gran variedad de datos, como signos vitales, resultados de laboratorio, indicadores clínicos, características demográficas o puntuaciones de cuestionarios. Gracias a ella pueden identificarse patrones, valorar tendencias y comprender la variabilidad en el estado de salud de los pacientes o en los fenómenos estudiados. El documento destaca cuatro grandes utilidades: resumir datos clínicos, identificar tendencias y patrones, evaluar la efectividad de las intervenciones y apoyar la toma de decisiones.

## 2. Conceptos generales: universo, población y muestra

### 2.1. Universo

El universo representa la totalidad de los individuos o elementos que poseen determinadas características y que, por ello, podrían ser susceptibles de ser estudiados. Desde un punto de vista conceptual, es el conjunto más amplio al que se refiere la investigación. En la práctica, suele ser tan grande que resulta imposible estudiar a todos sus integrantes. El documento lo presenta como la totalidad de individuos o elementos sobre los que podría, en sentido amplio, recaer el interés investigador.

### 2.2. Población

La población es el conjunto de individuos o elementos que cumplen los requerimientos o criterios de inclusión definidos para el estudio y sobre los que interesa obtener conclusiones. En investigación, la población suele ser el grupo real sobre el cual se pretende hacer inferencia estadística. Aunque es más concreta que el universo, también suele ser demasiado grande para

estudiarla por completo con los medios humanos y técnicos disponibles. Por ello, normalmente se recurre a una muestra.

## 2.3. Población finita e infinita

Las poblaciones pueden clasificarse en finitas e infinitas. Una población finita es aquella que puede medirse o enumerarse, es decir, aquella en la que existe un límite identificable al número de sujetos o elementos. Una población infinita es aquella en la que, a efectos prácticos, no existe un límite operativo respecto al número de observaciones que pueden generarse. Esta distinción tiene relevancia conceptual y, en algunos casos, estadística, especialmente cuando se abordan cálculos muestrales o modelos teóricos.

## 2.4. Muestra

La muestra es el subconjunto de la población al que se tiene acceso y sobre el que realmente se van a realizar las observaciones. Para que una muestra sea útil debe ser representativa de la población de la que procede y debe estar formada por elementos seleccionados a partir de la población de interés. Su principal ventaja es que permite obtener información similar a la que se obtendría si se estudiara toda la población general, pero con menos coste, menos tiempo y mayor viabilidad práctica.

# 3. Las variables en estadística descriptiva

## 3.1. Qué se entiende por variable

En estadística, una variable es una característica o cualidad de un individuo, objeto o suceso que puede tomar distintos valores. Esa característica puede medirse y variar entre diferentes individuos u observaciones dentro de una población o muestra. Por ejemplo, si se estudia la presión arterial de un grupo de pacientes, la presión arterial es una variable, y cada paciente tendrá un valor concreto para ella. La existencia de distintos valores posibles es lo que da lugar a la variabilidad de los datos.

## 3.2. Importancia de identificar correctamente las variables

El tipo de variable utilizado influye de forma determinante en varias fases posteriores del estudio. En primer lugar, condiciona el tipo de tratamiento estadístico que podrá aplicarse. En segundo lugar, afecta a la selección del instrumento de medida y de recogida de datos, que debe ajustarse a la naturaleza del dato. Y en tercer lugar, determina qué tipo de análisis será adecuado cuando se estudien los resultados obtenidos. Por tanto, clasificar correctamente las variables no es solo una cuestión terminológica, sino una decisión metodológica central.

# 4. Clasificación de las variables según su nivel de medición

## 4.1. Variables cualitativas

Las variables cualitativas describen categorías o cualidades y no expresan cantidades numéricas en sentido estricto. Pueden clasificarse en dicotómicas, nominales y ordinales.

### 4.1.1. Variable cualitativa dicotómica

Es aquella que solo puede tomar dos valores posibles. Ejemplos clásicos son sí/no, presencia/ausencia, fumador/no fumador, adherencia/no adherencia. Aunque a veces pueda

codificarse numéricamente, sigue siendo una variable cualitativa porque esos números representan categorías y no magnitudes.

#### *4.1.2. Variable cualitativa nominal*

Es aquella que puede tomar varias categorías, pero sin que exista entre ellas un orden natural. Por ejemplo: grupo sanguíneo, profesión, nacionalidad, tipo de dieta o carrera universitaria. Las categorías son diferentes entre sí, pero una no es “mayor” ni “menor” que otra.

#### *4.1.3. Variable cualitativa ordinal*

Es aquella que puede tomar distintas categorías y, además, esas categorías presentan un orden o jerarquía. Ejemplos serían el grado de dolor leve-moderado-intenso, el nivel de satisfacción bajo-medio-alto o los estadios de una enfermedad cuando expresan progresión. La variable ordinal permite ordenar, pero no asegura que la distancia entre categorías sea equivalente.

### **4.2. Variables cuantitativas**

Las variables cuantitativas expresan cantidades numéricas y permiten operaciones matemáticas con sentido estadístico.

#### *4.2.1. Variable cuantitativa discreta*

Es aquella que puede tomar un número definido de valores enteros, normalmente derivados de un recuento. Ejemplos: número de hijos, número de ingresos hospitalarios, número de caries o número de medicamentos prescritos.

#### *4.2.2. Variable cuantitativa continua*

Es aquella que puede tomar cualquier valor dentro de un intervalo determinado. Suele surgir de una medición y admite decimales. Ejemplos: peso, talla, glucemia, temperatura, presión arterial o tiempo de recuperación.

## **5. Clasificación de las variables según el diseño o la relación causa-efecto**

### **5.1. Variable dependiente**

La variable dependiente es aquella que se mide o se observa como respuesta a la manipulación o influencia de otra variable. En estudios experimentales o en diseños centrados en relaciones causa-efecto, es el resultado que se analiza para valorar si cambia en función de la variable independiente. Puede haber varias variables dependientes en un mismo estudio. Ejemplo: si se estudia el efecto de un programa de actividad física sobre las horas de sueño, la cantidad de horas de sueño sería una variable dependiente.

### **5.2. Variable independiente**

La variable independiente, también llamada predictora o explicativa, es aquella que se manipula, controla o se considera causa potencial de un cambio en otra variable. Está asociada al factor que se cree que afecta a la variable dependiente. En un diseño experimental, es la variable cuya modificación se estudia para ver su impacto. Siguiendo el ejemplo anterior, la participación o no en el programa de actividad física sería la variable independiente.

### 5.3. Ejemplos de identificación de variables

El documento propone como ejercicio identificar tipos de variables en preguntas como la que analiza cómo afecta la participación en programas de actividad física al número de horas de sueño y a la calidad del sueño, considerando además la variabilidad entre carreras universitarias. En ese ejemplo, la participación en programas de actividad física actuaría como variable independiente; las horas de sueño serían una variable cuantitativa continua dependiente; la calidad del sueño podría medirse como ordinal o cuantitativa según el instrumento utilizado; y la carrera universitaria sería una variable cualitativa nominal.

Otro ejemplo es la evaluación del impacto de un programa educativo sobre rendimiento académico, nivel de satisfacción y preferencia por métodos de estudio. Aquí, la participación en el programa educativo sería la variable independiente; el rendimiento académico, una variable dependiente cuantitativa; la satisfacción, probablemente una variable ordinal; y la preferencia por métodos de estudio, una variable cualitativa nominal.

## 6. Otras variables de interés en investigación

### 6.1. Variable confusora

Una variable confusora, también llamada factor de confusión, es una variable adicional que está relacionada tanto con la variable independiente como con la variable dependiente en un estudio. Su presencia puede distorsionar la interpretación de la relación entre ambas variables, haciendo que parezca más fuerte o más débil de lo que realmente es.

El documento ofrece un ejemplo claro: en un estudio sobre una intervención nutricional y pérdida de peso, el nivel de actividad física podría actuar como variable confusora. Si los participantes más activos físicamente pierden más peso, podría atribuirse erróneamente esa pérdida a la intervención nutricional cuando, en realidad, el ejercicio también está contribuyendo de forma importante. Para controlar este factor, pueden utilizarse estrategias como la estratificación o la inclusión de la variable como covariable en el análisis estadístico.

### 6.2. Variable dummy

La variable dummy, también llamada variable indicadora o binaria, es un tipo especial de variable que suele tomar solo dos valores, habitualmente 0 y 1, y se utiliza para representar información cualitativa o categórica de forma numérica. Son especialmente útiles en modelos de regresión y otros análisis estadísticos donde es necesario introducir categorías en forma compatible con procedimientos matemáticos.

Un ejemplo clásico es la variable sexo con dos categorías: masculino y femenino. Para incluirla en un modelo, puede crearse una variable dummy como “Masculino”, que tome el valor 1 si la persona es hombre y 0 si es mujer. Esto no convierte el sexo en una magnitud cuantitativa real, pero sí permite incorporarlo al análisis estadístico.

## 7. Qué son los estadísticos descriptivos

Los estadísticos descriptivos son números obtenidos a partir de los datos de una muestra o conjunto de observaciones. Sirven para recopilar, clasificar y analizar las características de la muestra utilizada en un estudio, de modo que permitan al investigador plantear conclusiones sobre su composición y estructura. En el documento se agrupan en cuatro grandes categorías: medidas de posición, medidas de centralización, medidas de dispersión y medidas de forma.

### Medidas de posición

#### 8.1. Concepto general

Las medidas de posición describen la posición relativa de un valor dentro de un conjunto de datos. Resultan esenciales para comprender dónde se sitúa una observación respecto al resto de la distribución. Se basan en los cuantiles, es decir, en divisiones ordenadas del conjunto de datos. Los cuantiles más utilizados son percentiles, cuartiles y deciles.

#### 8.2. Percentiles

Los percentiles dividen un conjunto de datos en 100 partes iguales. El percentil K indica el valor por debajo del cual se encuentra el K % de los datos. Por ejemplo, si un recién nacido se sitúa en el percentil 71 de peso al nacer, eso significa que su peso es superior al de aproximadamente el 70 % de los neonatos de referencia. Los percentiles son muy útiles en contextos clínicos y de desarrollo, por ejemplo para valorar crecimiento, evolución de parámetros o detección de situaciones de riesgo.

#### 8.3. Cuartiles

Los cuartiles dividen el conjunto de datos en cuatro partes iguales. El primer cuartil (Q1) deja por debajo el 25 % de los datos; el segundo cuartil (Q2) coincide con la mediana y deja por debajo el 50 %; y el tercer cuartil (Q3) deja por debajo el 75 %. El documento recuerda además la equivalencia entre cuartiles y percentiles: Q1 corresponde al percentil 25, Q2 al percentil 50 y Q3 al percentil 75.

#### 8.4. Rango intercuartílico

El rango intercuartílico (RIC) es la diferencia entre Q3 y Q1. Representa el 50 % central de las observaciones y es una medida muy útil para describir dispersión cuando la distribución es asimétrica o existen valores extremos. El documento ilustra este concepto con un ejemplo de tiempos de recuperación postquirúrgica, en el que el RIC permite describir el núcleo central de la distribución con más robustez que otras medidas sensibles a outliers.

## 9. Medidas de centralización o tendencia central

#### 9.1. Concepto general

Las medidas de centralización, también denominadas medidas de tendencia central, son valores numéricos que se sitúan alrededor del centro de la distribución y respecto a los cuales los datos tienden a agruparse. Las tres medidas clásicas son la media aritmética, la mediana y la moda. El documento las presenta como herramientas básicas para resumir una distribución mediante un único valor representativo.

#### 9.2. Media aritmética

La media aritmética es el promedio de un conjunto de datos. Se obtiene sumando todos los valores y dividiendo el resultado entre el número total de observaciones. Es una medida muy

utilizada por su sencillez y por la gran cantidad de procedimientos estadísticos que se apoyan en ella. Sin embargo, es sensible a los valores extremos.

### 9.3. Mediana

La mediana es el valor que divide la distribución en dos grupos con el mismo número de observaciones, es decir, el percentil 50. Es especialmente conveniente cuando los datos son asimétricos y no es sensible a valores extremos. Si el número de datos es impar, la mediana es el valor central; si es par, se calcula como la media de los dos valores centrales.

El documento ilustra esta diferencia con un ejemplo de tiempos de recuperación en el que un valor extremo de 15 horas eleva la media hasta 7,5 horas, mientras que la mediana queda en 6,5 horas y representa mejor el tiempo típico de recuperación para la mayoría de los pacientes. Este ejemplo es muy útil para mostrar al alumnado por qué la elección entre media y mediana depende de la distribución de los datos.

### 9.4. Moda

La moda es el valor que aparece con mayor frecuencia en un conjunto de datos. Puede existir una sola moda (distribución unimodal), dos modas (bimodal), varias modas (multimodal) o ninguna moda clara (amodal). Es especialmente útil en variables cualitativas y en distribuciones donde interesa conocer la categoría o valor más frecuente.

## 10. Medidas de dispersión

### 10.1. Concepto general

Las medidas de dispersión proporcionan información sobre la variabilidad o extensión de un conjunto de datos. Mientras las medidas de tendencia central indican dónde se sitúa el centro de la distribución, las medidas de dispersión indican cuánto se alejan o se acercan los datos respecto a ese centro. El documento insiste en que estas medidas deben acompañar siempre a las de tendencia central, porque juntas ofrecen una visión mucho más completa de la distribución.

### 10.2. Rango

El rango es la diferencia entre el valor máximo y el valor mínimo de una muestra o población. Indica entre qué valores se distribuyen las observaciones. Es una medida sencilla y útil para una primera aproximación, pero muy sensible a valores extremos, ya que solo depende de las observaciones más alejadas.

### 10.3. Varianza

La varianza mide el promedio de las desviaciones cuadradas de las observaciones respecto a la media. Refleja hasta qué punto los datos se dispersan alrededor del promedio. Aunque es una medida fundamental en estadística, presenta la desventaja de estar expresada en unidades cuadradas, lo que a veces dificulta su interpretación directa.

### 10.4. Desviación típica o estándar

La desviación típica es la raíz cuadrada de la varianza. Ofrece una medida de dispersión respecto a la media y tiene la ventaja de mantener la misma unidad de medida que la variable original. Al igual que la varianza, es sensible a valores extremos y se interpreta mejor cuando la media es una medida adecuada del centro de la distribución.

### 10.5. Coeficiente de variación

El coeficiente de variación se utiliza para estandarizar la variabilidad de una distribución independientemente de las unidades de medida. Se calcula dividiendo la desviación típica entre el valor absoluto de la media y, en ocasiones, se expresa en porcentaje. Su utilidad principal es comparar la dispersión relativa entre variables distintas o entre grupos con medias diferentes. El documento propone como criterio práctico que, si el coeficiente de variación es menor del 50 %, la media puede considerarse representativa; si supera el 50 %, debe cuestionarse; y si supera el 100 %, la media deja de ser representativa. También advierte que no debe utilizarse cuando el cero es arbitrario, como ocurre con escalas de temperatura como Celsius o Fahrenheit.

## 11. Medidas de forma

### 11.1. Concepto general

Las medidas de forma permiten valorar cómo es la distribución de los datos más allá de su centro y su dispersión. Son de interés porque ayudan a identificar si una distribución es simétrica o no, si está muy apuntada o aplanada y, en consecuencia, orientan la elección de herramientas estadísticas posteriores. El documento distingue dos grandes medidas de forma: la asimetría y la curtosis.

### 11.2. Asimetría

La asimetría permite identificar si los datos se distribuyen de forma uniforme alrededor del punto central o si están desplazados hacia uno de los lados. Una distribución puede ser simétrica, presentar asimetría positiva o presentar asimetría negativa. Según el documento, en la asimetría positiva la distribución se prolonga hacia la derecha; en la asimetría negativa, hacia la izquierda; y cuando la distribución es aproximadamente simétrica, ambos lados respecto a la media presentan un comportamiento semejante. También se citan coeficientes de asimetría de Fisher y Pearson como formas de cuantificar esta propiedad.

### 11.3. Curtosis

La curtosis mide el grado de concentración de los valores alrededor de la región central de la distribución y también se conoce como medida de apuntamiento. Se interpreta comparando la distribución observada con una distribución normal. Si el coeficiente es aproximadamente cero, la distribución es mesocúrtica o normal; si es mayor que cero, la distribución es leptocúrtica o más apuntada; y si es menor que cero, es platicúrtica o más aplanada. La curtosis proporciona información adicional sobre la forma de la distribución y puede ser relevante al seleccionar métodos de análisis.

## 12. Representación gráfica de los datos

### 12.1. Utilidad general de los gráficos

Las representaciones gráficas son herramientas visuales que permiten presentar la información de manera más accesible y comprensible. Facilitan la interpretación, la comparación y el análisis exploratorio de los datos. El documento destaca que los gráficos ayudan a visualizar patrones y tendencias, comparar datos, comunicar resultados de manera efectiva, resumir distribuciones, apoyar la toma de decisiones, identificar valores atípicos y seguir cambios a lo largo del tiempo. La elección del gráfico dependerá del tipo de variable, de los datos disponibles y de los objetivos del análisis.

### *13. Diagrama de barras*

El diagrama de barras representa las frecuencias observadas mediante barras rectangulares. Se construye sobre ejes de coordenadas: en el eje de abscisas se sitúan las categorías o valores de la variable y en el eje de ordenadas las frecuencias absolutas, relativas o acumuladas. Es especialmente útil para variables cualitativas —nominales u ordinales— y también puede utilizarse con variables cuantitativas discretas. Las barras son independientes y separadas entre sí, lo que facilita la comparación visual entre categorías. Puede presentarse en formato vertical u horizontal.

### *14. Histograma*

El histograma se utiliza principalmente con variables cuantitativas continuas o con variables discretas agrupadas en intervalos. En él, la base de cada barra representa la amplitud del intervalo y la altura refleja la frecuencia correspondiente. La superficie de cada barra es proporcional a la frecuencia, lo que permite visualizar la distribución de los datos, detectar asimetrías, apreciar el grado de dispersión y sospechar la presencia de determinados patrones o valores atípicos. El documento señala que, aunque es muy útil para estudiar la forma de una distribución, aporta menos información descriptiva detallada que el box-plot.

### *15. Diagrama de sectores*

El diagrama de sectores representa la proporción de cada categoría respecto al total mediante sectores de un círculo. Resulta especialmente adecuado para variables cualitativas nominales u ordinales, y también puede emplearse con algunas variables discretas. Su principal ventaja es que permite visualizar de forma rápida la distribución porcentual de un conjunto de datos y comparar la participación relativa de diferentes categorías. Sin embargo, suele ser menos preciso que otros gráficos cuando hay muchas categorías o cuando las diferencias entre sectores son pequeñas.

### *16. Diagrama de dispersión*

El diagrama de dispersión representa la relación entre dos variables mediante puntos en un plano cartesiano. Cada punto corresponde a un par de observaciones, una para cada variable. Es especialmente útil para variables cuantitativas, tanto continuas como discretas. Permite visualizar relaciones, identificar patrones de correlación, observar tendencias lineales o no lineales y detectar posibles valores atípicos que puedan afectar la relación entre ambas variables. Su valor es especialmente alto en fases exploratorias del análisis.

### *17. Series temporales o gráfico de líneas*

Las series temporales representan la evolución de una variable a lo largo del tiempo. En el eje horizontal se sitúan los puntos temporales o fechas, y en el eje vertical los valores observados. Son especialmente útiles para mostrar tendencias temporales, identificar patrones estacionales y facilitar predicciones o pronósticos basados en comportamientos pasados. El documento menciona aplicaciones en salud pública, economía e investigación clínica, por ejemplo para seguir la incidencia de enfermedades, la evolución de indicadores económicos o la progresión de parámetros clínicos en pacientes.

### *18. Box-plot o diagrama de caja*

#### *18.1. Qué representa*

El box-plot es una representación gráfica que permite visualizar con gran facilidad varios parámetros estadísticos de una distribución: tendencia central, variabilidad, asimetría y

presencia de valores atípicos. Se construye a partir de los cuartiles y de los valores extremos de la distribución.

#### 18.2. La caja

La caja central representa la zona donde se concentra la mitad central de los datos. Su límite inferior corresponde al primer cuartil (Q1 o percentil 25), su límite superior al tercer cuartil (Q3 o percentil 75), y en su interior se representa la mediana (Q2 o percentil 50) mediante una línea horizontal. Esta configuración permite apreciar de forma inmediata la amplitud del rango intercuartílico y la posición relativa de la mediana dentro de la distribución.

#### 18.3. Los bigotes y los valores atípicos

Los bigotes prolongan la caja hacia los extremos y muestran la variabilidad fuera del rango intercuartílico, pero solo hasta un límite de 1,5 veces el RIC. Los valores que quedan más allá de esos límites se identifican individualmente como outliers o valores atípicos. Esta representación permite detectar rápidamente observaciones inusuales y valorar la simetría o asimetría de la distribución. El documento recuerda además una idea importante: que un lado de la caja sea más largo que otro no significa que ese lado contenga más datos, sino que esos datos están más dispersos.

#### 18.4. Utilidad del box-plot

El box-plot permite resumir en un solo gráfico información sobre mediana, cuartiles, dispersión y valores atípicos. También facilita la comparación entre grupos y la valoración visual de la simetría. Si la mediana está aproximadamente en el centro de la caja y los bigotes son de longitud semejante, la distribución sugiere simetría; si no, puede sospecharse asimetría. Por ello, es uno de los gráficos más completos dentro de la estadística descriptiva.

## 8. Relación entre variable, medida descriptiva y gráfico

Uno de los aprendizajes más importantes que transmite el documento es que no todas las medidas ni todos los gráficos son adecuados para cualquier variable. La elección debe hacerse de forma coherente. Por ejemplo, para variables cualitativas suelen usarse frecuencias, porcentajes, diagramas de barras o sectores; para variables cuantitativas con distribución aproximadamente simétrica, media y desviación típica; para variables cuantitativas asimétricas, mediana y rango intercuartílico; y para relaciones entre dos variables cuantitativas, diagramas de dispersión. Esta coherencia entre tipo de variable, forma de expresión y representación gráfica es una competencia básica en estadística aplicada.

## 9. Conclusiones

La estadística descriptiva constituye una herramienta fundamental para organizar, resumir y comprender los datos obtenidos en investigación y práctica clínica. Permite describir las características de una muestra, identificar patrones, valorar la variabilidad y comunicar la información de forma clara mediante medidas numéricas y representaciones gráficas.

Para utilizarla correctamente es necesario comprender bien los conceptos de universo, población y muestra, identificar adecuadamente los distintos tipos de variables y saber qué medidas descriptivas y qué gráficos son apropiados en cada caso. Las medidas de posición, centralización, dispersión y forma aportan información complementaria sobre una distribución, y los gráficos facilitan una comprensión visual que muchas veces resulta imprescindible para interpretar correctamente los datos.

En definitiva, la estadística descriptiva no es una colección aislada de fórmulas, sino una base metodológica esencial para cualquier profesional o investigador que necesite leer, interpretar, presentar y utilizar datos con rigor en ciencias de la salud.