

1. Introducción a la estadística inferencial

1.1. Qué es la estadística inferencial

La estadística inferencial es la rama de la estadística que permite extrapolar información desde una muestra hacia una población. Su función principal es utilizar los datos obtenidos en un grupo más pequeño para formular estimaciones, contrastar hipótesis y tomar decisiones sobre un grupo más amplio, teniendo siempre en cuenta la incertidumbre asociada al muestreo. Esta idea aparece de forma explícita en el documento, que la define como el conjunto de técnicas que permiten trasladar la información obtenida en la muestra a la población, cuantificando al mismo tiempo la incertidumbre de esa extrapolación.

1.2. Por qué es necesaria

En la mayor parte de las investigaciones en ciencias de la salud no resulta posible estudiar a toda la población de interés. Por ello, se selecciona una muestra y se trabaja con ella. Sin embargo, el verdadero interés científico no suele limitarse a describir esa muestra concreta, sino a formular conclusiones sobre la población de la que procede. La estadística inferencial hace posible ese paso, utilizando herramientas como los intervalos de confianza y las pruebas de hipótesis para cuantificar el grado de certeza o incertidumbre asociado a las conclusiones.

2. Conceptos generales: población, muestra, parámetros y estadísticos

2.1. Población

La población es el conjunto completo de elementos que tienen una característica en común y que resultan de interés para el estudio. Por ejemplo, si el interés se centra en la altura de todas las personas adultas, la población estaría formada por todos los adultos. Esta definición, aparentemente sencilla, es fundamental porque toda inferencia estadística pretende decir algo sobre esa población, aunque los datos se obtengan solo de una parte de ella.

2.2. Muestra

La muestra es un subconjunto representativo de la población que se selecciona para realizar el estudio. En el ejemplo del documento, si se quisiera estudiar la altura de los adultos, podría medirse la altura de 100 de ellos como muestra. La idea de representatividad resulta clave, porque la calidad de la inferencia dependerá en buena medida de que esa muestra se parezca razonablemente a la población de la que procede.

2.3. Parámetros

Un parámetro es una medida numérica que describe una característica de la población completa. Por ejemplo, la media de altura de todos los adultos sería un parámetro. En la práctica, los parámetros poblacionales suelen ser desconocidos, y precisamente por eso se recurre a técnicas de estimación.

2.4. Estadísticos

Un estadístico es una medida numérica que describe una característica de la muestra. Por ejemplo, la media de altura de los 100 adultos seleccionados sería un estadístico. Los estadísticos muestrales son observables y calculables, y se utilizan como aproximaciones de los parámetros poblacionales desconocidos.

3. Estimación estadística

3.1. Concepto de estimación

La estimación es el proceso de calcular y proporcionar una aproximación de un parámetro desconocido de una población a partir de la información recogida en una muestra representativa. El parámetro a estimar puede ser una media, una proporción, una desviación estándar, una diferencia de medias u otra característica numérica de la población. La lógica inferencial parte de la idea de que una muestra adecuadamente seleccionada ofrece información útil sobre la población, aunque siempre con cierto margen de error.

3.2. Tipos de estimación

El documento distingue dos grandes modalidades de estimación: la estimación puntual y la estimación por intervalo. La primera ofrece un único valor como mejor aproximación del parámetro poblacional. La segunda ofrece un rango de valores plausibles dentro del cual se espera que se sitúe el verdadero valor del parámetro con un determinado nivel de confianza.

4. Estimación puntual

4.1. Qué es una estimación puntual

La estimación puntual consiste en proporcionar un solo valor como estimación del parámetro poblacional. Por ejemplo, afirmar que la media de altura de los adultos es de 170 cm constituye una estimación puntual. Se trata de una forma simple y directa de resumir la información muestral, pero presenta una limitación evidente: no informa sobre el grado de precisión ni sobre la incertidumbre asociada a esa estimación.

4.2. Utilidad y limitaciones

La estimación puntual es útil porque ofrece una cifra concreta y fácilmente interpretable. Sin embargo, es incompleta cuando se pretende inferir a la población, ya que no muestra cuánto podría variar esa estimación si se extrajeran otras muestras de la misma población. El propio documento resume esta idea con una comparación pedagógica: la estimación puntual sería una “foto”, mientras que el intervalo de confianza sería un “pequeño vídeo” de lo que podría ser el valor verdadero.

4.3. Estadísticos habituales en estimación puntual

Cuando la variable es cuantitativa, la estimación puntual suele apoyarse en la media como estadístico principal. Cuando la variable es cualitativa dicotómica o se desea resumir una característica categórica, se utiliza la proporción como estadístico. En ambos casos, la estimación puntual debe entenderse como una aproximación al parámetro poblacional correspondiente.

5. Error estándar

5.1. Qué es el error estándar

Dentro de la estimación aparece el concepto de error estándar, que mide la variabilidad de los estadísticos muestrales si se extrajeran múltiples muestras de la misma población. El documento lo explica como la dispersión “imaginaria” que presentarían las distintas medias o proporciones obtenidas en muestras repetidas. Por tanto, el error estándar está directamente relacionado con la calidad o precisión de la estimación. Cuanto menor sea, más estable y precisa será la estimación puntual.

5.2. Error estándar de la media

El error estándar de la media se refiere a la variabilidad de las medias muestrales alrededor de la verdadera media poblacional. Puede entenderse como la desviación estándar de todas las posibles medias muestrales de un determinado tamaño extraídas de esa población. Su fórmula habitual es $SEM = S / \sqrt{n}$, donde S es la desviación estándar muestral y n el tamaño de la muestra.

5.3. Error estándar de la proporción

Cuando la variable es cualitativa y el estadístico de interés es una proporción, se utiliza el error estándar de la proporción. Este cuantifica la variabilidad de las proporciones muestrales alrededor de la verdadera proporción poblacional. El documento lo vincula a la dispersión esperable de los porcentajes obtenidos en diferentes muestras.

5.4. Cómo se expresa en un documento científico

El error estándar suele acompañar a la estimación puntual como indicador de precisión. Por ejemplo, una media puede expresarse como “165,2 ± 2,5 cm”, donde 165,2 representa la media muestral y 2,5 el error estándar de esa media. Del mismo modo, una proporción puede expresarse como “0,75 ± 0,05”. Esta forma de presentación no sustituye al intervalo de confianza, pero da una idea preliminar de la precisión de la estimación.

6. Estimación por intervalo

6.1. Qué es un intervalo de confianza

La estimación por intervalo proporciona un rango de valores plausible para un parámetro poblacional a partir de los datos de una muestra. No ofrece una sola cifra, sino un intervalo dentro del cual se espera que se encuentre el verdadero valor del parámetro con un cierto nivel de confianza. Esta estrategia es metodológicamente superior a la estimación puntual aislada cuando se quiere valorar precisión e incertidumbre.

6.2. Características del intervalo de confianza

El intervalo de confianza se construye a partir de datos muestrales. Para que sea interpretable, la muestra debe ser representativa y, idealmente, seleccionada de forma aleatoria. El intervalo se interpreta como un rango de valores plausibles para el parámetro, asociado a un nivel de confianza —habitualmente 90 %, 95 % o 99 %— que expresa el grado de certeza del procedimiento. El documento insiste en que esta interpretación es probabilística: no garantiza que el valor verdadero esté dentro del intervalo en un caso concreto, pero sí que, si el proceso

se repitiera muchas veces, el porcentaje indicado de intervalos contendría el verdadero parámetro.

6.3. Nivel de confianza y nivel de significación

El nivel de confianza representa la probabilidad de que el intervalo de confianza capture el verdadero valor del parámetro. Se expresa como $1-\alpha$. El nivel de significación α representa, por tanto, la porción que queda fuera del intervalo, es decir, el riesgo asumido de que el verdadero valor no esté dentro de él. Los valores más habituales son $\alpha = 0,05$ y $\alpha = 0,01$, correspondientes a niveles de confianza del 95 % y 99 %, respectivamente. El documento relaciona explícitamente ambos conceptos y recuerda que el nivel de confianza se utiliza en la construcción de intervalos, mientras que el nivel de significación se vincula sobre todo al contraste de hipótesis.

6.4. Qué se necesita para construir un intervalo de confianza

Para construir un intervalo de confianza es necesario disponer, al menos, de cuatro elementos: el tamaño de la muestra, el nivel de confianza elegido, el margen de error asociado a la estimación y el estadístico muestral sobre el que se va a construir el intervalo, como una media, una proporción o una diferencia de medias. El documento recalca que el tamaño muestral influye directamente en la amplitud del intervalo: cuanto mayor sea la muestra, más estrecho tiende a ser el intervalo y, por tanto, mayor precisión suele alcanzarse.

7. Intervalos de confianza para la media

7.1. Supuestos generales

La estimación por intervalo de la media poblacional se basa en el supuesto de que la distribución de muestreo sea normal o, en su defecto, en la aplicación del teorema central del límite. El documento resume de forma práctica esta idea indicando que, para la mayoría de distribuciones poblacionales, la distribución muestral de la media será aproximadamente normal si el tamaño de la muestra es al menos de 30 observaciones.

7.2. Casos habituales

El material muestra tres escenarios clásicos: intervalo de confianza para la media con varianza conocida, con varianza desconocida y muestra pequeña, y con varianza desconocida y muestra grande. Aunque aparecen las fórmulas específicas, la idea didáctica principal es que la distribución de referencia cambia según se conozca o no la varianza y según el tamaño muestral, recurriéndose a z o t según corresponda.

7.3. Ejemplo de interpretación de una media

Se presenta un ejemplo en el que se calcula un IC95 % para la media de horas de sueño al día en personal de farmacia, obteniéndose un intervalo entre 6,8 y 7,5 horas. La interpretación correcta, según el documento, es que con un 95 % de confianza se estima que la media poblacional de horas de sueño se encuentra entre esos valores. Además, si se repitiera el muestreo muchas veces, alrededor del 95 % de los intervalos construidos contendrían la verdadera media.

8. Interpretación de la amplitud del intervalo de confianza

8.1. Qué indica la amplitud

La amplitud del intervalo de confianza, también llamada margen de error, proporciona información sobre la precisión de la estimación. Un intervalo estrecho indica una estimación más precisa; un intervalo ancho sugiere mayor incertidumbre. Esta relación entre anchura del intervalo y precisión es una de las ideas más importantes de la inferencia, porque obliga a no quedarse solo con el valor central de la estimación.

8.2. Factores que influyen en la amplitud

El documento identifica varios factores que modifican la anchura del intervalo: la estimación puntual, la desviación estándar o el error estándar, el nivel de confianza y el tamaño de la muestra. Un nivel de confianza más alto genera intervalos más amplios; una muestra mayor tiende a generar intervalos más estrechos; y una mayor variabilidad en los datos ensancha el intervalo.

8.3. La amplitud siempre debe interpretarse en contexto

La presentación añade una observación muy pertinente: no existe una amplitud “buena” o “mala” de forma absoluta. Todo depende del contexto específico del estudio. En algunos casos clínicos puede ser imprescindible una gran precisión; en otros, un intervalo más amplio puede resultar aceptable si la naturaleza del fenómeno o de la muestra lo justifican.

9. Intervalos de confianza para diferencias y razones

9.1. Diferencia de medias y diferencia de proporciones

Cuando el parámetro de interés es una diferencia —por ejemplo, diferencia de medias o diferencia de proporciones—, el criterio central de interpretación consiste en comprobar si el intervalo incluye o no el valor 0. Si el IC95 % no incluye 0, puede afirmarse que hay una diferencia concluyente entre grupos. Si el intervalo sí incluye 0, el resultado es no concluyente. El documento resume esta regla de forma muy clara y la ejemplifica con comparaciones de bienestar, presión sistólica o adherencia.

9.2. Razón de varianzas, OR y RR

Cuando el parámetro de interés es una razón, como una razón de varianzas, una odds ratio o un riesgo relativo, el valor de referencia ya no es 0, sino 1. Si el intervalo no incluye 1, la asociación o diferencia es concluyente; si lo incluye, el resultado es no concluyente. Esta regla aparece de forma explícita tanto para varianzas como para OR y RR.

10. Contraste de hipótesis

10.1. Qué es un contraste de hipótesis

El contraste de hipótesis es un procedimiento estadístico que se utiliza para tomar decisiones sobre afirmaciones hechas acerca de una población basándose en la información recopilada de

una muestra. Su objetivo es evaluar la evidencia en contra de una afirmación nula en favor de una afirmación alternativa. Por tanto, no se trata de “demostrar” una hipótesis, sino de valorar si los datos son suficientemente incompatibles con una hipótesis nula como para rechazarla.

10.2. Hipótesis nula e hipótesis alternativa

La hipótesis nula (H_0) es la afirmación que se somete a prueba y que se asume como válida hasta que la evidencia estadística indique lo contrario. Suele plantear igualdad, ausencia de efecto o ausencia de diferencia. La hipótesis alternativa (H_1) es la afirmación opuesta, la que se desea respaldar con la evidencia, y suele formularse en términos de diferencia, mayor que o menor que. El documento insiste en que la hipótesis alternativa no debe aceptarse sin evidencia sólida.

10.3. Hipótesis simples y compuestas

Las hipótesis pueden ser simples, cuando asignan un único valor al parámetro, o compuestas, cuando establecen un intervalo o una desigualdad. Dentro de estas últimas aparecen las formulaciones bilaterales, unilaterales a la derecha y unilaterales a la izquierda. Esta clasificación es importante porque condiciona el tipo de contraste y la interpretación posterior.

11. Errores en el contraste de hipótesis

11.1. Error de tipo I

El error de tipo I consiste en rechazar la hipótesis nula cuando en realidad es verdadera. Es el error asociado al nivel de significación α . En términos prácticos, equivale a concluir que existe un efecto, una diferencia o una asociación cuando en realidad no existe. El documento lo ejemplifica como la situación en la que un tratamiento no tiene efecto, pero el experimento lleva a decidir que sí lo tiene.

11.2. Error de tipo II

El error de tipo II consiste en no rechazar la hipótesis nula cuando en realidad es falsa. Se asocia con β . En la práctica, significa que un tratamiento sí tiene efecto, pero el estudio no logra detectarlo. Este error se relaciona con la potencia estadística, ya que $1-\beta$ representa la probabilidad de detectar un efecto real cuando efectivamente existe.

11.3. Una advertencia metodológica importante

El documento hace una advertencia especialmente relevante: el contraste de hipótesis no “prueba” la hipótesis alternativa. Solo evalúa cuán compatibles son los datos con la hipótesis nula. Esta precisión es esencial para evitar interpretaciones excesivas o erróneas de la significación estadística.

12. P-valor, intervalo de confianza y tamaño del efecto

12.1. El p-valor

El p-valor es la probabilidad de obtener un resultado igual o más extremo que el observado si la hipótesis nula fuera cierta. El documento insiste en dos aclaraciones fundamentales: sí es una medida de compatibilidad entre datos y H_0 , pero no es la probabilidad de que H_0 sea verdadera y no mide el tamaño del efecto ni garantiza importancia clínica. En la lógica clásica, si $p < \alpha$, el resultado se considera estadísticamente significativo y se rechaza H_0 ; si $p \geq \alpha$, no se rechaza.

12.2. Relación entre p-valor e intervalo de confianza

En pruebas bilaterales, si el IC95 % no cruza el valor nulo —0 en diferencias y 1 en razones—, entonces el resultado suele corresponder a $p < 0,05$. Si el intervalo sí cruza el valor nulo, el resultado suele corresponder a $p > 0,05$. Esta relación permite enseñar que p-valor e intervalo de confianza no son herramientas independientes, sino dos formas complementarias de expresar la evidencia estadística.

12.3. Tamaño del efecto

El tamaño del efecto es una medida de cuánto de grande es la diferencia o la relación encontrada, más allá de su significación estadística. Mientras el p-valor informa sobre compatibilidad con la hipótesis nula, el tamaño del efecto informa sobre relevancia práctica, clínica u operativa. El documento destaca varias medidas: d de Cohen para diferencias de medias entre dos grupos independientes, r de Pearson para asociación lineal entre variables continuas, η^2 parcial para ANOVA, ϕ o V de Cramér para tablas de contingencia y OR para asociaciones entre exposición y evento. También propone umbrales orientativos de interpretación.

12.4. Interpretación integrada

Una de las aportaciones más útiles del documento es la propuesta de combinar siempre tres dimensiones: evidencia estadística, magnitud del efecto y precisión. Primero debe valorarse si hay evidencia de efecto mediante p-valor o IC. Después debe valorarse el tamaño del efecto para juzgar relevancia práctica. Y, por último, debe atenderse a la amplitud del IC como indicador de precisión. Esta integración permite evitar conclusiones simplistas del tipo “es significativo, por tanto es importante”.

13. Pruebas paramétricas y no paramétricas

13.1. La necesidad de comprobar supuestos

El documento subraya que, antes de elegir una prueba estadística, es imprescindible comprobar si los datos cumplen ciertos supuestos. En variables continuas, los dos supuestos más importantes son la normalidad de la distribución y la homocedasticidad de las varianzas en grupos independientes. En diseños pareados o de medidas repetidas, la atención se desplaza a la distribución de las diferencias y, en ciertos casos, a la esfericidad.

13.2. Normalidad

La normalidad implica que la variable, o las diferencias en diseños pareados, sigue aproximadamente una distribución normal. El documento recomienda comprobarla primero con gráficos, como histogramas y Q–Q plots, y después con pruebas estadísticas. Las dos pruebas mencionadas son Shapiro–Wilk y Kolmogorov–Smirnov, aunque se enfatiza especialmente Shapiro–Wilk por su potencia en muestras pequeñas y medianas. Si $p \geq 0,05$, no hay evidencia para rechazar normalidad; si $p < 0,05$, hay evidencia de no normalidad.

13.3. Homocedasticidad

La homocedasticidad hace referencia a la igualdad aproximada de varianzas entre grupos independientes. Se comprueba con el test de Levene. Si $p \geq 0,05$, puede asumirse homogeneidad de varianzas; si $p < 0,05$, hay evidencia de heterocedasticidad y deben elegirse alternativas robustas, como t de Welch o ANOVA de Welch. El documento recuerda además que este supuesto no aplica a diseños pareados.

14. Inferencia con un solo grupo

14.1. Una sola muestra con variable cualitativa

Cuando se trabaja con un solo grupo y una variable cualitativa dicotómica, el contraste habitual es la prueba exacta binomial si la muestra es pequeña o las proporciones son extremas, o la prueba z de una proporción si la muestra es grande. Si la variable cualitativa tiene tres o más categorías, la prueba habitual es la chi-cuadrado de bondad de ajuste, que valora si la distribución observada coincide o no con una distribución teórica esperada.

14.2. Una sola muestra con variable cuantitativa

Cuando se trabaja con una sola muestra y una variable cuantitativa continua, el test habitual es la t de una muestra si se cumple normalidad. Esta prueba contrasta si la media poblacional es igual a un valor de referencia μ_0 . Si no se cumple normalidad o los datos son ordinales, puede utilizarse la prueba no paramétrica de Wilcoxon para una muestra, que contrasta si la mediana difiere de un valor de referencia.

14.3. Ejemplos docentes

El documento aporta un ejemplo de t de una muestra con horas de sueño del personal farmacéutico comparadas con 7,5 horas al día. Tras comprobar normalidad, se obtiene $p = 0,037$, un IC95 % que no incluye 7,5 y un tamaño del efecto mediano. También se presenta un ejemplo de Wilcoxon de una muestra para estrés laboral en enfermeras de atención primaria, con $p = 0,028$, un efecto grande y una interpretación basada en mediana y cambio típico. Estos ejemplos son útiles porque integran prueba, p-valor, IC y tamaño del efecto.

15. Inferencia con dos grupos

15.1. Dos grupos con variable cuantitativa: grupos independientes

Cuando se comparan dos grupos independientes con una variable cuantitativa continua, deben seguirse varios pasos. Primero, confirmar que los grupos son realmente independientes. Después, comprobar normalidad por grupo mediante Shapiro–Wilk y valorar homocedasticidad con Levene. Si hay normalidad y varianzas iguales, se utiliza la t de Student para muestras

independientes. Si hay normalidad pero varianzas desiguales, se utiliza la t de Welch. Si no hay normalidad o la variable es ordinal, se utiliza Mann–Whitney U.

15.2. Dos grupos con variable cuantitativa: grupos pareados

Si los datos son pareados o dependientes —por ejemplo, pre y post en las mismas personas—, la lógica cambia. En este caso debe construirse una variable diferencias y comprobar la normalidad de esas diferencias. Si la normalidad es aceptable, se utiliza la t pareada. Si no se cumple, se emplea Wilcoxon pareado. El documento insiste en que, en diseños pareados, no se evalúa homocedasticidad entre grupos.

15.3. Dos grupos con variable cualitativa

Cuando ambas variables son cualitativas y los grupos son independientes, la prueba habitual es la chi-cuadrado de independencia para tablas RxC, siempre que se cumplan criterios mínimos en las frecuencias esperadas. Si las celdas esperadas son demasiado pequeñas, deben reagruparse categorías o utilizarse procedimientos exactos, como Fisher en tablas 2x2. Si los datos son pareados y dicotómicos, la prueba adecuada es McNemar. Si se trata de la misma persona medida en tres o más momentos con variable binaria, se utiliza Cochran's Q.

15.4. Ejemplos docentes

La presentación incluye varios ejemplos: una t de Student para comparar bienestar entre dos formatos de formación, mostrando un caso con efecto grande y relevancia práctica, y otro caso con muestra muy grande donde la diferencia es estadísticamente significativa pero el tamaño del efecto es trivial. También se incluye un ejemplo de Wilcoxon pareado con reducción de estrés tras un taller y un ejemplo de chi-cuadrado de independencia con uso de app y abandono del programa, acompañado de RR, OR y tamaño del efecto ϕ . Estos ejemplos son muy valiosos porque muestran que significación estadística y relevancia práctica no siempre coinciden.

16. Inferencia con más de dos grupos

16.1. Introducción general

Cuando se comparan más de dos grupos, la lógica inferencial exige primero una prueba global que determine si existen diferencias entre al menos dos grupos y, posteriormente, comparaciones post-hoc para identificar dónde están esas diferencias. El documento distingue claramente entre grupos independientes y grupos pareados o de medidas repetidas.

16.2. Grupos independientes con variable cuantitativa

Si la variable dependiente es continua, hay normalidad aceptable y Levene indica homocedasticidad, se utiliza ANOVA de una vía. Si Levene indica varianzas desiguales, se recurre al ANOVA de Welch. Si la variable es ordinal o no se cumple normalidad, se emplea Kruskal–Wallis. El documento remarca que, en todos estos casos, la elección debe hacerse a partir de evidencias y no de costumbre.

16.3. Grupos pareados y esfericidad

Cuando se trabaja con tres o más medidas repetidas sobre las mismas personas, entra en juego el supuesto de esfericidad, propio del ANOVA de medidas repetidas. La esfericidad implica que las varianzas de todas las diferencias por pares entre niveles son iguales. Se comprueba con el test de Mauchly. Si se viola, deben aplicarse correcciones como Greenhouse–Geisser o Huynh–Feldt. Si los supuestos no se cumplen o la variable es ordinal, se utiliza Friedman.

16.4. Comparaciones post-hoc

Una prueba global significativa no dice entre qué grupos están las diferencias. Para ello se realizan comparaciones post-hoc, controlando el error asociado a comparaciones múltiples. El documento detalla que, tras ANOVA clásico, se usa Tukey; tras ANOVA de Welch, Games–Howell; tras Kruskal–Wallis, Dunn; tras ANOVA de medidas repetidas, comparaciones pareadas con ajustes como Bonferroni; y tras Friedman, Wilcoxon pareado con ajuste. Esta parte es especialmente útil porque conecta la prueba global con la interpretación práctica posterior.

16.5. Ejemplos docentes

Se incluye un ejemplo de ANOVA de una vía para comparar bienestar entre tres formatos de formación, con normalidad aceptable, homocedasticidad, F significativo, η^2 parcial de magnitud mediana y post-hoc de Tukey que muestran diferencias entre A y B y entre A y C, pero no entre B y C. También se desarrolla un ejemplo de Kruskal–Wallis para comparar nivel de dolor entre tres intervenciones, con post-hoc de Dunn e interpretación basada en medianas, p-valor y tamaño del efecto ϵ^2 . Estos ejemplos muestran con claridad cómo se integran supuestos, prueba global y análisis post-hoc.

17. Intervalos de confianza y medidas de concordancia

17.1. OR y RR con intervalos de confianza

El documento dedica un bloque específico a recordar que, en medidas de concordancia como OR y RR, la inclusión o no del valor 1 en el intervalo de confianza es decisiva para valorar significación estadística. Si el IC incluye 1, no hay evidencia significativa de asociación; si no lo incluye, sí la hay. Esta regla es esencial y debe enseñarse junto a la interpretación del valor puntual.

17.2. Ejemplos interpretativos

Se presentan varios ejemplos: una vacuna con RR = 0,50 e IC95 % (0,32; 0,78), que se interpreta como efecto protector concluyente; un email de recordatorio con RR = 0,86 e IC95 % (0,60; 1,22), cuyo resultado es no concluyente; y una app de autorregistro con OR = 2,43 e IC95 % (1,21; 4,87), que se interpreta como mayor odds de abandono. Todos los ejemplos insisten en una idea fundamental: hay asociación estadística, pero no prueba automática de causalidad.

18. Ideas clave para la interpretación inferencial

18.1. No decidir solo con el p-valor

Una de las enseñanzas más valiosas del documento es que las decisiones inferenciales no deben apoyarse exclusivamente en el p-valor. Siempre deben considerarse conjuntamente el intervalo de confianza y el tamaño del efecto. El p-valor informa sobre compatibilidad con H_0 ; el intervalo de confianza informa sobre rango plausible y precisión; y el tamaño del efecto informa sobre relevancia práctica. La combinación de las tres dimensiones permite una interpretación más completa y científicamente más responsable.

18.2. Significación no equivale a relevancia

El documento muestra de forma muy clara que una diferencia estadísticamente significativa puede ser irrelevante en términos clínicos u operativos, especialmente con tamaños muestrales grandes. Del mismo modo, un resultado no significativo puede corresponder a un efecto de magnitud moderada si la muestra es pequeña y el intervalo es amplio, en cuyo caso la conclusión razonable no es que “no hay efecto”, sino que se necesitan más datos. Esta distinción es central en la enseñanza moderna de la estadística aplicada.

19. Conclusiones

La estadística inferencial permite pasar de la descripción de una muestra a la formulación de conclusiones sobre una población, siempre teniendo en cuenta la incertidumbre inherente al muestreo. Para ello se apoya en dos grandes estrategias: la estimación y el contraste de hipótesis. La estimación puede ser puntual o por intervalo, siendo esta última especialmente útil porque incorpora precisión e incertidumbre. El contraste de hipótesis, por su parte, permite valorar la compatibilidad entre datos e hipótesis nula, pero no debe interpretarse de manera simplista ni reducirse al p-valor.

A lo largo del proceso inferencial, conceptos como error estándar, nivel de confianza, nivel de significación, tamaño del efecto, normalidad, homocedasticidad y esfericidad adquieren un papel central. Asimismo, la correcta selección de pruebas —paramétricas o no paramétricas, para uno, dos o más grupos, independientes o pareados— depende del tipo de variable, del diseño y del cumplimiento de supuestos.

En definitiva, la estadística inferencial no consiste en aplicar pruebas de forma automática, sino en tomar decisiones metodológicas razonadas, interpretar resultados con prudencia y combinar evidencia estadística, magnitud del efecto y precisión de la estimación para extraer conclusiones científicamente sólidas y clínicamente relevantes.